ARQUITECTURA DEVOPS & INFRAESTRUCTURA DE PRODUCCIÓN

# DocEngine — Checklist de Despliegue a Producción

Guía Técnica Integral de Pase a Producción (Windows a Linux), Hardening de Sistema, Vectorización RAG, Gestión de Memoria para Modelos IA y Operaciones.

---

| | |
|---|---|
| **Sistema:** | DocEngine (Motor de Digitalización, Extracción OCR y Pipeline RAG) |
| **Versión de Entrega:** | 1.0.0 (Producción) |
| **Fecha de Emisión:** | Octubre 2026 |
| **Rol Responsable:** | Arquitecto DevOps & Sistemas |
| **Entorno Origen:** | Windows 11 (AMD Zen 4 / Workstation de Desarrollo) |
| **Entorno Destino:** | Linux x86_64 (Ubuntu 22.04 / 24.04 LTS o Rocky Linux 8.10 / 9) |
| **Stack Base:** | Python 3.12, FastAPI, Docling 2.0+, RapidOCR, PyTorch (bge-m3), PostgreSQL 16 + pgvector |

# 1. Gestión de Rutas y Modelos Locales

En la transición de Windows a Linux, el sistema de archivos pasa de ser insensible a mayúsculas/minúsculas (*case-insensitive*) y utilizar barras invertidas (`\`), a ser **estrictamente sensible (*case-sensitive*)** y requerir rutas normalizadas POSIX (`/`). Se han auditado y resuelto los siguientes puntos críticos del código fuente:

## 1.1 Sensibilidad y Carga de Reglas Skills (`company_skill_loader.py`)

La función `load_company_skill(sigla)` resuelve los archivos de reglas con el patrón `skills/skill-{canonical_sigla.lower()}.md` partiendo de `_DEFAULT_SKILLS_DIR = Path(__file__).resolve().parents[2] / "skills"`.

- **Riesgo en Linux:** Si en el directorio `/opt/docengine/skills/` existe algún archivo con mayúsculas (ej. `Skill-BISA.md` o `skill-BISA.md`), la resolución en Linux fallará silenciosamente, reportando *"Company skill file not found"* y omitiendo las reglas específicas de la aseguradora.
- **Validación Requerida:** Verificar que todos los archivos en disco se mantengan estrictamente en minúsculas: `skill-bisa.md`, `skill-cre.md`, `skill-ali-seg.md`, `skill-general.md`, etc.

## 1.2 Caché Persistente de Modelos de IA (PyTorch, HuggingFace y RapidOCR)

El código en `app/config/settings.py` (L44-56), `embedding_service.py` (L48-57) y `reranker_service.py` implementa un fallback a `tempfile.gettempdir() / "huggingface"` cuando el usuario del sistema tiene un `$HOME` no existente o no escribible (típico de usuarios de servicio o contenedores).

> **ALERTA DE PRODUCCIÓN:** Si la aplicación se ejecuta bajo un usuario de servicio sin home persistente, los modelos (`BAAI/bge-m3` de 2.2 GB y `bge-reranker-v2-m3` de 2.2 GB) se guardarán en `/tmp`. Los mecanismos del sistema (`systemd-tmpfiles-clean` o reinicios) purgarán periódicamente `/tmp`, provocando descargas masivas repetitivas que degradarán el ancho de banda y congelarán el arranque del servicio.

**Configuración Segura Obligatoria:** Crear un directorio persistente dedicado y enlazarlo en el entorno:

```
sudo mkdir -p /var/cache/docengine/{huggingface,torch,rapidocr}
sudo chown -R docengine:docengine /var/cache/docengine
sudo chmod -R 750 /var/cache/docengine
```

## 1.3 Rutas de Subida y Salida de Archivos

En `app/api/v1/extraction.py` (L144), los archivos cargados se guardan temporalmente en: `Path("outputs") / "_uploads" / f"{uuid.uuid4()}_{file.filename}"`.

- En producción, el valor de `DOCENGINE_OUTPUT_OUTPUT_DIR` debe ser obligatoriamente una ruta absoluta: `/opt/docengine/outputs`.
- El directorio `/opt/docengine/outputs/_uploads` debe tener permisos de escritura (`rwx`) para el usuario `docengine`.

# 2. Dependencias del Sistema y Entorno Virtual en Linux

DocEngine utiliza librerías de aceleración C++, bindings de OpenCV y modelos ONNX/PyTorch. Se deben instalar las dependencias de sistema a nivel del sistema operativo antes de configurar el entorno virtual.

## 2.1 Paquetes del Sistema Operativo

**En Ubuntu 22.04 / 24.04 LTS:**

```
sudo apt-get update && sudo apt-get install -y --no-install-recommends     python3.12 python3.12-venv python3.12-dev     build-esse
```

**En Rocky Linux 8.10 / 9 (o RHEL):**

```
sudo dnf install -y epel-release
sudo dnf install -y python3.12 python3.12-devel     gcc gcc-c++ make libgomp mesa-libGL glib2     tesseract tesseract-langpack-spa
```

## 2.2 Creación del Entorno Virtual e Instalación Paso a Paso

**DEPENDENCIA CRÍTICA PROPIETARIA:** El proyecto incluye el archivo wheel `pdfextract-1.0.0-py3-none-any.whl` en la raíz. Como `DOCENGINE_EXTRACTOR_ENGINE=pdfextract` es el motor predeterminado (`app/api/main.py` L45), este wheel **debe ser instalado explícitamente** en el virtualenv. De lo contrario, la API fallará al arrancar con `ModuleNotFoundError: No module named 'pdfextract'`.

Comandos exactos para recrear el entorno limpio:

```
# 1. Crear usuario de sistema dedicado
sudo useradd -r -s /bin/false -d /opt/docengine docengine
sudo mkdir -p /opt/docengine
sudo chown -R docengine:docengine /opt/docengine

# 2. Situarse en el directorio del código
cd /opt/docengine

# 3. Crear entorno virtual aislado con Python 3.12
python3.12 -m venv .venv
source .venv/bin/activate

# 4. Actualizar instaladores base de Python
pip install --no-cache-dir --upgrade pip setuptools wheel

# 5. Instalar dependencias de producción
pip install --no-cache-dir -r requirements.txt

# 6. Instalar el paquete propietario local pdfextract
pip install --no-cache-dir ./pdfextract-1.0.0-py3-none-any.whl

# 7. Precalentar y cachear pesos de modelos ONNX y Embeddings en disco
python -c "from rapidocr_onnxruntime import RapidOCR; RapidOCR()"
python -c "from sentence_transformers import SentenceTransformer; SentenceTransformer('BAAI/bge-m3')"
```

# 3. Variables de Entorno y Secrets (Archivo `.env`)

El motor de configuración se gestiona mediante `AppSettings` en `app/config/settings.py` utilizando `pydantic-settings`, junto con validaciones de seguridad en `app/api/security.py`.

## 3.1 Tabla de Parámetros de Configuración

| Variable | Valor Producción | Propósito Técnico |
|---|---|---|
| `DOCENGINE_ENV` | `production` | Normaliza a modo producción (activa formateador de logs JSON). |
| `DOCENGINE_EXTRACTOR_ENGINE` | `pdfextract` | Motor de extracción activo (`pdfextract` o `docling`). |
| `DOCENGINE_SECURITY_ENABLED` | `true` | Exige autenticación mediante cabecera `X-API-Key` en endpoints API. |
| `DOCENGINE_API_KEYS` | `{"key":"role",...}` | Mapeo JSON de API Keys a privilegios (`readonly`, `writer`, `admin`). |
| `DOCENGINE_DB_HOST` | `127.0.0.1` | Host del servidor PostgreSQL 16 con extensión pgvector. |
| `DOCENGINE_DB_POOL_MIN / MAX` | `4 / 20` | Dimensionamiento del pool de conexiones multihilo (psycopg2). |
| `OPENAI_API_KEY` | `sk-proj-...` | Credencial para generación RAG y extracción estructurada (gpt-4.1-mini / gpt-4o). |
| `DOCENGINE_PIPELINE_NUM_THREADS` | `8` | Hilos CPU dedicados a la descomposición de páginas en Docling. |
| `DOCENGINE_PIPELINE_IMAGES_SCALE` | `1.0` | Escala estándar de renderizado (1.0 = 72 DPI), previene desbordamiento de RAM. |
| `DOCENGINE_EMBED_BATCH_SIZE` | `8` | Batch size óptimo para inferencia de bge-m3 en CPU Linux (evita padding cuadrático). |
| `DOCENGINE_LOG_FORMAT` | `json` | Salida JSON estructurada estándar para ingesta por syslog/journald/ELK. |
| `HF_HOME / TORCH_HOME` | `/var/cache/docengine/...` | Directorios de almacenamiento persistente de pesos para evitar re-descargas. |

El archivo completo listo para despliegue se presenta a continuación con todos los parámetros pre-sintonizados para entornos Linux de alta concurrencia.

## 3.2 Archivo de Producción Completo: `/opt/docengine/.env`

```
# ============================================================================
# DOCENGINE — CONFIGURACIÓN DE PRODUCCIÓN (LINUX)
# Ubicación: /opt/docengine/.env | Permisos: 600 (docengine:docengine)
# ============================================================================

DOCENGINE_ENV=production
DOCENGINE_APP_NAME=DocEngine
DOCENGINE_APP_VERSION=1.0.0
DOCENGINE_EXTRACTOR_ENGINE=pdfextract
DOCENGINE_SKIP_SKILLS=false

# --- Seguridad y Control de Acceso (RBAC) ---
DOCENGINE_SECURITY_ENABLED=true
DOCENGINE_API_KEYS={"prod-read-789a6c2f":"readonly","prod-write-91b4d3e1":"writer","prod-admin-82c4f1a0":"admin"}

# --- Base de Datos PostgreSQL + pgvector ---
DOCENGINE_DB_HOST=127.0.0.1
DOCENGINE_DB_PORT=5432
DOCENGINE_DB_NAME=docengine
DOCENGINE_DB_USER=docengine_app
DOCENGINE_DB_PASSWORD=CAMBIAR_POR_PASSWORD_SEGURO_PROD
DOCENGINE_DB_POOL_MIN=4
DOCENGINE_DB_POOL_MAX=20

# --- OpenAI API (LLM) ---
OPENAI_API_KEY=sk-proj-xxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxxx
DOCENGINE_RAG_LLM_MODEL=gpt-4.1-mini
DOCENGINE_RAG_MAX_TOKENS=16384
DOCENGINE_RAG_TEMPERATURE=0.0
DOCENGINE_RAG_TOP_K=10
DOCENGINE_RAG_SIMILARITY_THRESHOLD=0.20

# --- Pipeline de Extracción y OCR ---
DOCENGINE_EXTRACTION_DO_OCR=true
DOCENGINE_EXTRACTION_FORCE_OCR_ALL_PAGES=false
DOCENGINE_EXTRACTION_AUTO_DETECT_PDF_TYPE=true
DOCENGINE_EXTRACTION_TABLE_MODE=ACCURATE
DOCENGINE_EXTRACTION_DO_TABLE_STRUCTURE=true
DOCENGINE_EXTRACTION_DO_CELL_MATCHING=true
DOCENGINE_EXTRACTION_FIX_SPACED_TEXT=true
DOCENGINE_EXTRACTION_SPLIT_MERGED_TABLES=true
DOCENGINE_OCR_ENGINE=rapidocr
DOCENGINE_OCR_LANGUAGES=["es","en"]

# --- Pipeline Técnico Docling y Embeddings ---
DOCENGINE_PIPELINE_NUM_THREADS=8
DOCENGINE_PIPELINE_ACCELERATOR_DEVICE=cpu
DOCENGINE_PIPELINE_PDF_BACKEND=docling_parse_v2
DOCENGINE_PIPELINE_IMAGES_SCALE=1.0
DOCENGINE_EMBED_MODEL_NAME=BAAI/bge-m3
DOCENGINE_EMBED_BATCH_SIZE=8
DOCENGINE_EMBED_NUM_THREADS=6
DOCENGINE_EMBED_DEVICE=cpu
DOCENGINE_EMBED_CHUNK_SIZE_CHARS=2500
DOCENGINE_EMBED_CHUNK_OVERLAP_CHARS=200
DOCENGINE_RERANKER_ENABLED=false

# --- Almacenamiento, Rendimiento y Logging ---
DOCENGINE_OUTPUT_OUTPUT_DIR=/opt/docengine/outputs
DOCENGINE_OUTPUT_INCLUDE_METADATA=true
DOCENGINE_OUTPUT_INCLUDE_REPORT=true
DOCENGINE_PERF_BATCH_SIZE=8
DOCENGINE_PERF_MAX_UPLOAD_SIZE_MB=500
DOCENGINE_PERF_REQUEST_TIMEOUT_SECONDS=300
DOCENGINE_LOG_LEVEL=INFO
DOCENGINE_LOG_FORMAT=json
DOCENGINE_LOG_LOG_FILE=/var/log/docengine/docengine.log

# --- Caché Persistente y Entorno Matemático ---
HF_HOME=/var/cache/docengine/huggingface
SENTENCE_TRANSFORMERS_HOME=/var/cache/docengine/huggingface
TRANSFORMERS_CACHE=/var/cache/docengine/huggingface
TORCH_HOME=/var/cache/docengine/torch
TORCHDYNAMO_DISABLE=1
TORCH_COMPILE_DISABLE=1
OMP_NUM_THREADS=6
MKL_NUM_THREADS=6
```

# 4. Base de Datos y Vectorización (PostgreSQL 16 + pgvector)

DocEngine utiliza PostgreSQL 16 con la extensión vectorial `vector` (dimensión 1024 para BAAI/bge-m3) y un esquema relacional/híbrido compuesto por 12 migraciones correlativas ubicadas en el directorio `scripts/`.

## 4.1 Preparación de la Base de Datos y Extensión

```
# 1. Instalar PostgreSQL 16 y extensión pgvector (Ubuntu)
sudo apt-get install -y postgresql-16 postgresql-16-pgvector

# 2. Crear base de datos, usuario y habilitar pgvector
sudo -u postgres psql << 'EOF'
CREATE DATABASE docengine;
CREATE USER docengine_app WITH ENCRYPTED PASSWORD 'CAMBIAR_POR_PASSWORD_SEGURO_PROD';
GRANT ALL PRIVILEGES ON DATABASE docengine TO docengine_app;
\c docengine
CREATE EXTENSION IF NOT EXISTS vector;
GRANT ALL ON SCHEMA public TO docengine_app;
EOF
```

## 4.2 Ejecución Automatizada de Migraciones

El script `scripts/init_db.py` lee la configuración desde `settings.database`, detecta todos los archivos SQL ordenados alfabéticamente (desde `001_add_rag_tables.sql` hasta `012_add_client_name_search_indexes.sql`) y los ejecuta en modo autocommit.

```
cd /opt/docengine && source .venv/bin/activate
python scripts/init_db.py
```

## 4.3 Catálogo de Migraciones Ejecutadas

| Archivo de Migración | Objetivo en el Esquema |
|---|---|
| `001_add_rag_tables.sql` | Crea extensión `vector`, tablas `policies`, `policy_chunks` (vector 1024), `policy_raw_md`, `policy_structured_data` y trabajos. |
| `002_parent_child_hybrid_search.sql` | Añade columnas `chunk_id`, `parent_id`, y columna generada `content_tsvector` con índice GIN para búsqueda en español. |
| `003_add_processing_stats_table.sql` | Crea tabla `processing_stats` para auditoría de tiempos, páginas y consumo de CPU. |
| `004_add_policy_envelope.sql` | Agrupación de documentos por Sobre de Póliza (`policy_envelopes`). |
| `005_add_id_cliente.sql` | Columna indexada `id_cliente` (Carnet de Identidad o NIT) en sobres y pólizas. |
| `006_add_master_catalogs.sql` | Catálogos maestros APS: `cat_aseguradoras`, `cat_tipos_documento`, `cat_ramos`. |
| `007_align_stats_company_sigla.sql` | Alineación de siglas de aseguradoras en estadísticas. |
| `008_add_policy_section_summaries.sql` | Tabla de resúmenes de secciones para navegación contextual rápida de pólizas grandes. |
| `009_add_policy_fleet_vehicles.sql` | Tabla estructurada para flotillas de vehículos (placas, chasis, sumas aseguradas). |
| `010_add_policy_insured_persons.sql` | Tabla de personas aseguradas para colectivos de vida, salud y accidentes. |
| `011_add_nombre_cliente.sql` | Columna de nombre o razón social del cliente / tomador. |
| `012_add_client_name_search_indexes.sql` | Índices funcionales B-tree `LOWER(nombre_cliente)` para búsquedas ágiles ILIKE. |

## 5. Demonización y Servicios (Systemd)

En producción, la API se gestiona mediante `systemd`. Es mandatorio utilizar **1 solo worker de Uvicorn**. Como cada proceso carga en memoria los modelos de visión, OCR y embeddings (consumiendo entre 2 y 4 GB de RAM), múltiples workers duplicarían innecesariamente los pesos estáticos en memoria. La concurrencia se resuelve mediante I/O asíncrono y los hilos internos de inferencia (OpenMP / PyTorch).

### 5.1 Archivo de Servicio: `/etc/systemd/system/docengine.service`

```
[Unit]
Description=DocEngine — API de Extracción Documental y RAG
Documentation=https://github.com/alturasoft/docengine
After=network.target postgresql.service
Wants=postgresql.service

[Service]
Type=exec
User=docengine
Group=docengine
WorkingDirectory=/opt/docengine

# Archivo de variables de entorno de producción
EnvironmentFile=/opt/docengine/.env

# Ejecución a través del entorno virtual con 1 worker
ExecStart=/opt/docengine/.venv/bin/uvicorn main:app     --host 127.0.0.1     --port 8000     --workers 1     --log-level info     

# Ciclo de vida y reinicios
Restart=always
RestartSec=10s
TimeoutStartSec=120s
TimeoutStopSec=30s

# --- LÍMITES DE SISTEMA PARA MODELOS IA ---
# Bloqueo de memoria en RAM: previene que los pesos de los modelos sean enviados a SWAP
LimitMEMLOCK=infinity
# Descriptores de archivos para subida masiva de PDFs y sockets de red
LimitNOFILE=65536
# Permite suficientes hilos para OpenMP, PyTorch y Tokenizers concurrentes
LimitNPROC=4096
# Evita que systemd limite la creación de hilos a bajo nivel en C++
TasksMax=infinity

# --- SEGURIDAD Y SANDBOXING ---
PrivateTmp=true
ProtectSystem=full
ProtectHome=true
NoNewPrivileges=true
ReadWritePaths=/opt/docengine/outputs /var/log/docengine /var/cache/docengine

[Install]
WantedBy=multi-user.target
```

### 5.2 Comandos de Activación del Servicio

```
sudo systemctl daemon-reload && sudo systemctl enable docengine
sudo systemctl start docengine && sudo systemctl status docengine
```

# 6. Almacenamiento, Logs y Permisos

## 6.1 Matriz de Permisos de Directorios

| Directorio | Usuario / Grupo | Permiso | Contenido |
|---|---|---|---|
| `/opt/docengine/outputs` | `docengine:docengine` | `750 (rwxr-x---)` | Markdown extraído, JSONs, carpetas `_uploads` temporales. |
| `/opt/docengine/skills` | `docengine:docengine` | `755 (rwxr-xr-x)` | Archivos de reglas de negocio por aseguradora (Solo Lectura). |
| `/var/log/docengine` | `docengine:docengine` | `750 (rwxr-x---)` | Logs estructurados JSON (`docengine.log`). |
| `/var/cache/docengine` | `docengine:docengine` | `750 (rwxr-x---)` | Pesos cacheados de Hugging Face, Torch y RapidOCR. |

## 6.2 Rotación de Logs (`/etc/logrotate.d/docengine`)

```
/var/log/docengine/*.log {
    daily
    missingok
    rotate 14
    compress
    delaycompress
    notifempty
    create 0640 docengine docengine
    sharedscripts
    postrotate
        systemctl kill -s HUP docengine.service >/dev/null 2>&1 || true
    endscript
}
```

## 6.3 Proxy Inverso Nginx (`/etc/nginx/sites-available/docengine`)

```
server {
    listen 80;
    server_name docengine.tudominio.com;

    client_max_body_size 500M;
    client_body_timeout 300s;

    location / {
        proxy_pass http://127.0.0.1:8000;
        proxy_http_version 1.1;
        proxy_set_header Host $host;
        proxy_set_header X-Real-IP $remote_addr;
        proxy_set_header X-Forwarded-For $proxy_add_x_forwarded_for;
        proxy_set_header X-Forwarded-Proto $scheme;
        proxy_read_timeout 300s;
        proxy_connect_timeout 60s;
        proxy_send_timeout 300s;
    }
}
```

# 7. Protocolo de Pruebas Post-Despliegue (Smoke Tests)

```
# 1. Healthcheck general del servicio y base de datos
curl -s http://127.0.0.1:8000/api/v1/health | jq .

# 2. Verificación de versiones y motor activo (debe reportar pdfextract)
curl -s http://127.0.0.1:8000/api/v1/version | jq .

# 3. Test de subida y extracción con autenticación RBAC
curl -X POST "http://127.0.0.1:8000/api/v1/extract"   -H "X-API-Key: prod-write-91b4d3e1"   -F "file=@samples/test_policy.pdf"   -F

# 4. Monitoreo de logs estructurados en vivo
sudo journalctl -u docengine.service -f -o cat
```