DOCENGINE REST API • ESPECIFICACIÓN TÉCNICA v1.1

DocEngine — Especificación Técnica de Endpoints y APIs

Manual integral de integración y arquitectura para analistas y desarrolladores. Ingesta documental, motor de sobres, persistencia vectorial, consultas semánticas RAG, extracción estructurada JSON y control de acceso RBAC.

Plataforma:	DocEngine (FastAPI + IBM Docling + PostgreSQL pgvector)
Versión de la API:	v1.1.0 (Prefijo global: `/api/v1`)
Formatos de Datos:	JSON (UTF-8) / multipart/form-data
Fecha de Emisión:	Octubre 2026
Estado del Documento:	Especificación Técnica Oficial y Operativa (9 Endpoints y Requerimientos Integrados)

Índice del Contenido

1. Visión General: Propósito, formatos de intercambio y arquitectura de sobres.

2. Entornos y URLs Base: Direcciones por ciclo de vida (Desarrollo, Staging, Producción) y OpenAPI.

3. Autenticación y Autorización (RBAC): Mecanismos de seguridad, cabecera `X-API-Key` y roles de usuario.

4. Convención Global de Errores y Respuestas: Estructura estándar `ErrorDetailSchema` y códigos HTTP admitidos.

5. Paginación y Filtros Avanzados: Reglas de consulta por aseguradora, ramo, número de póliza, tipo de documento y vigencia.

6. Catálogo Detallado de Endpoints:
• *6.1 Módulo Extraction:* Ingesta síncrona/asíncrona (`async_mode`), consulta de jobs, límites y catálogo de aseguradoras.

• *6.2 Módulo Policies & Envelopes:* Datos estructurados de póliza (Cláusula 2da), reemplazo de documentos sueltos y gestión de sobres.

• *6.3 Módulo RAG Query:* Búsqueda pura de fragmentos y score (sin LLM) y consultas semánticas con síntesis.

• *6.4 Módulo System & Health:* Monitoreo de latido, métricas de rendimiento y buffer de logs.

7. Límites Técnicos por Archivo y Rendimiento: Restricciones de tamaño (200 MB), páginas (500 págs) y validación de PDF.

8. Procesamiento Asíncrono, Idempotencia y Reintentos: Hashing SHA-256, ciclo de vida de jobs y condicionados generales.

1. Visión General

DocEngine es una plataforma de servicios de alto rendimiento diseñada para la digitalización, extracción estructurada, clasificación y consulta conversacional (RAG) de pólizas de seguro en Bolivia.

El sistema procesa documentos PDF complejos (nativos o escaneados con OCR), normaliza la estructura visual a Markdown estructurado y JSON, fragmenta el contenido en jerarquías *Parent-Child*, genera representaciones vectoriales densas de 1024 dimensiones utilizando el modelo local **BAAI/bge-m3**, y almacena la información tanto relacional como vectorialmente en **PostgreSQL con la extensión pgvector**.

Principios Clave de la API

- **Versionado Estricto:** Todos los endpoints de negocio están bajo la ruta base `/api/v1/` , garantizando evolución controlada y compatibilidad hacia atrás.
- **Formato Estándar:** Todas las peticiones y respuestas estructuradas utilizan **JSON** codificado en **UTF-8** (salvo la carga de archivos binarios vía `multipart/form-data`).
- **Idempotencia Nativa:** Toda ingesta documental verifica el hash criptográfico SHA-256 del archivo; si el documento ya fue procesado, no se reprocesa innecesariamente, evitando costos de cómputo y duplicación de vectores.
- **Arquitectura de Sobres (Policy Envelopes):** Los documentos no existen aislados; se agrupan lógicamente en "sobres" que representan la póliza completa (agrupando carátula, condicionados generales, condicionados particulares, liquidaciones y anexos).
- **Aislamiento Multi-Inquilino (id_cliente):** Cada operación de ingesta y consulta puede aislarse por identificador de cliente, garantizando la privacidad de los datos.

2. Entornos y URLs Base

La API se despliega de forma desacoplada y puede consumirse a través de los siguientes endpoints base según el ciclo de vida del software:

Entorno	URL Base de Endpoints	Documentación Swagger UI	Propósito
Desarrollo Local	`http://localhost:8000/api/v1`	`http://localhost:8000/docs`	Pruebas locales, ejecución directa con Uvicorn.
Staging / Pruebas	`http://192.168.1.50:8000/api/v1`	`http://192.168.1.50:8000/docs`	Validación de integración y QA con clientes internos.
Producción	`https://docengine.altura.bo/api/v1`	`https://docengine.altura.bo/docs`	Servidor productivo de alta concurrencia.

> **Documentación Interactiva y OpenAPI Versionado**
> DocEngine expone la especificación OpenAPI v3 estándar en `/openapi.json` y provee interfaces interactivas para pruebas en `/docs` (Swagger UI) y `/redoc` (ReDoc). La especificación exportada se mantiene sincronizada y versionada en `docs/openapi.json` bajo la política de versionado `docs/API_VERSIONING_POLICY.md`.

3. Autenticación y Autorización (RBAC)

DocEngine implementa un esquema de seguridad basado en claves de API (`X-API-Key`) con control de acceso basado en roles (**RBAC**). El sistema puede operar en modo abierto (para redes internas/desarrollo local) o en modo autenticado estricto mediante la variable de entorno `DOCENGINE_SECURITY_ENABLED=true`.

Cabecera HTTP de Autenticación

```
X-API-Key: <TU_API_KEY_SECRETA>
```

Perfiles de Acceso (Roles)

Rol	Permisos Otorgados	Endpoints Habilitados
`readonly`	Lectura y búsqueda	`POST /api/v1/query/search`, `POST /api/v1/query`, `GET /api/v1/policies/*` (incluye datos estructurados), `GET /api/v1/health/*`.
`writer`	Lectura + Ingesta documental	Todos los permisos de `readonly` más `POST /api/v1/extract/*` y `GET /api/v1/extract/jobs/*`.
`admin`	Control total	Todos los permisos anteriores más `DELETE /api/v1/policies/{policy_id}` y `DELETE /api/v1/policies/envelopes/{envelope_id}`.

4. Convención Global de Errores y Respuestas

DocEngine se adhiere a las mejores prácticas de diseño RESTful y convenciones estándar de FastAPI/Starlette con esquemas de error estandarizados.

Estructura Estándar de Error JSON (ErrorDetailSchema)

```
{
  "detail": "Descripción precisa y legible del motivo del error o validación",
  "error_code": "INVALID_PAGE_COUNT",
  "timestamp": "2026-10-14T18:00:00Z"
}
```

Códigos de Estado HTTP Admitidos

Código HTTP	Significado	Contexto en DocEngine
200 OK	Éxito síncrono	La petición se procesó exitosamente y se retorna la información solicitada.
202 Accepted	Procesamiento asíncrono	La carga fue validada y puesta en cola en segundo plano; incluye `job_id` para consulta de estado.
400 Bad Request	Petición inválida	Parámetros incorrectos, archivo con formato no admitido (solo PDF) o archivo PDF corrupto/dañado.
401 Unauthorized	No autenticado	Falta la cabecera `X-API-Key` o la clave provista es inválida.
403 Forbidden	Acceso denegado	La clave tiene rol insuficiente para la operación solicitada (ej. rol `readonly` intentando eliminar).
404 Not Found	No encontrado	El sobre (`envelope_id`), documento (`policy_id`) o trabajo (`job_id`) no existe.
413 Content Too Large	Archivo excedido	El tamaño del archivo supera el límite configurado (por defecto **200 MB**).
422 Unprocessable Content	Validación / Límite páginas	Error en formato de datos Pydantic o el PDF supera el límite máximo permitido de **500 páginas**.
500 Internal Error	Fallo de servidor	Excepción no controlada en el motor de extracción Docling o en PostgreSQL.
503 Service Unavailable	Servicio no disponible	El motor vectorial o la base de datos se encuentran fuera de línea o en inicialización.

5. Paginación y Filtros Avanzados

Tanto los endpoints de búsqueda vectorial (`/query/search`) como los de gestión de sobres admiten filtros estructurados combinables mediante el objeto `SearchFiltersSchema` :

Filtro	Tipo	Descripción	Ejemplo
`id_cliente`	string	Aislamiento multi-inquilino estricto por cliente.	`"CLI-001"`
`sigla_aseguradora`	string	Sigla oficial normalizada contra el catálogo maestro (18 aseguradoras).	`"BISA"`, `"CRI"`
`ramo`	string	Ramo de seguro técnico normalizado.	`"AUTOMOTOR"`, `"INCENDIO"`
`numero_poliza`	string	Búsqueda exacta o parcial sobre el número de póliza.	`"POL-2024-9988"`
`tipo_documento`	string	Tipo documental: `POLIZA`, `CONDICIONADO_GENERAL`, etc.	`"CONDICIONADO_GENERAL"`
`vigencia_fecha`	string (ISO)	Filtra documentos cuya vigencia abarque la fecha especificada (`YYYY-MM-DD`).	`"2024-06-15"`

6. Catálogo Detallado de Endpoints

6.1 Módulo de Ingesta y Extracción Documental (Extraction)

`POST` **`/api/v1/extract/file`**

Propósito: Carga un archivo PDF binario para extracción, chunking y vectorización. Soporta ejecución síncrona inmediata o asíncrona mediante el parámetro `async_mode=true`.

Content-Type: `multipart/form-data`

Campo Form	Tipo	Requerido	Descripción
`file`	Binary (PDF)	**Sí**	Archivo PDF (máximo 200 MB y 500 páginas).
`id_cliente`	string	No	Identificador único del cliente para aislamiento multi-tenant.
`company_sigla`	string	No	Sigla oficial de la aseguradora (ej. `BISA`, `CRI`, `ALI`).
`numero_poliza`	string	No	Número de póliza para vinculación en sobre.
`ramo`	string	No	Ramo de la póliza (ej. `AUTOMOTOR`).
`tipo_documento`	string	No	Tipo de documento (ej. `POLIZA`, `CONDICIONADO_GENERAL`).
`async_mode`	boolean	No (def: false)	Si es `true`, encola la tarea en background y retorna `202 Accepted` con un `job_id`.

Respuesta Asíncrona (202 Accepted):

```
{
  "job_id": "d8e3b1c4-9a1f-4b12-a7e8-c51d9e2a4f00",
  "status": "PENDING",
  "message": "Extracción iniciada en segundo plano...",
  "check_status_url": "/api/v1/extract/jobs/d8e3b1c4-9a1f-4b12-a7e8-c51d9e2a4f00"
}
```

GET /api/v1/extract/jobs/{job_id}

Propósito: Consulta el estado de procesamiento de una carga asíncrona para documentos grandes o procesamiento por lotes.

Parámetro Path: `job_id` (string, UUID del trabajo).

Ejemplo de Respuesta (200 OK):

```
{
  "job_id": "d8e3b1c4-9a1f-4b12-a7e8-c51d9e2a4f00",
  "status": "COMPLETED",
  "progress_pct": 100,
  "created_at": "2026-10-14T17:30:00Z",
  "updated_at": "2026-10-14T17:30:25Z",
  "error_message": null,
  "result": {
    "policy_id": "POL-2024-9988",
    "id_cliente": "CLI-001",
    "chunks_indexed": 38,
    "total_pages": 45
  }
}
```

GET /api/v1/extract/companies

Propósito: Retorna el catálogo oficial de siglas y nombres completos de las compañías aseguradoras bolivianas soportadas por el motor.

6.2 Módulo de Pólizas y Gestión de Sobres (Policies & Envelopes)

GET `/api/v1/policies/{policy_id}/structured`

Propósito: Retorna el esquema JSON con los datos estructurados extraídos de la póliza (coberturas, límites, deducibles, valores asegurados y vigencias), correspondiente al objeto del contrato (Cláusula Segunda, incisos a y c).

Parámetro Path: `policy_id` (string, UUID del documento).

Ejemplo de Respuesta (200 OK):


```
{
  "policy_id": "4b684531-10df-4f40-84cf-8d9633e6c0c2",
  "id_cliente": "CLI-001",
  "aseguradora": "BISA SEGUROS Y REASEGUROS S.A.",
  "ramo": "AUTOMOTOR",
  "numero_poliza": "POL-2024-9988",
  "objeto_asegurado": "Vehículo Toyota Hilux 2023, Placa 4589-KLL",
  "coberturas": [
    {
      "nombre": "Responsabilidad Civil Extracontractual",
      "limite": "USD 20,000.00 por evento",
      "deducible": "10% de la pérdida, mín. USD 150.00"
    },
    {
      "nombre": "Pérdida Total por Accidente o Robo",
      "limite": "Valor Comercial Pactado (USD 35,000.00)",
      "deducible": "USD 200.00 fijo"
    }
  ],
  "deducibles": [
    {"cobertura": "Daños Propios", "monto": "USD 150.00"}
  ],
  "limites": [
    {"concepto": "Límite Máximo Agregado Anual", "monto": "USD 55,000.00"}
  ],
  "valores_asegurados": [
    {"item": "Vehículo Base", "monto": "USD 35,000.00", "moneda": "USD"}
  ],
  "vigencias": {
    "desde": "2024-01-01T00:00:00",
    "hasta": "2025-01-01T00:00:00"
  },
  "reglas_aplicadas": ["skill-bisa.md", "skill-general.md"]
}
```

DELETE /api/v1/policies/{policy_id}

Propósito: Elimina un documento individual suelto (por ejemplo, para reemplazar un anexo o condicionado erróneo sin eliminar la póliza completa). Desvincula el documento del sobre, elimina sus fragmentos vectoriales en cascada y limpia los archivos derivados en disco.

Parámetro Path: `policy_id` (string, UUID del documento a eliminar).

Ejemplo de Respuesta (200 OK):

```
{
  "policy_id": "4b684531-10df-4f40-84cf-8d9633e6c0c2",
  "deleted": true,
  "deleted_chunks": 24,
  "envelope_updated": true,
  "message": "Documento eliminado exitosamente de la base de datos y del disco."
}
```

GET /api/v1/policies/envelopes/{envelope_id}

Propósito: Retorna el detalle completo de un sobre y todos sus documentos asociados.

DELETE /api/v1/policies/envelopes/{envelope_id}

Propósito: Elimina de forma atómica y completa una póliza entera (sobre) y todos sus documentos asociados.

6.3 Módulo de Consultas Semánticas RAG (RAG Query)

POST `/api/v1/query/search`

Propósito: Endpoint de búsqueda pura que devuelve los fragmentos relevantes recuperados por similitud híbrida (denso + recíproco FTS) con sus metadatos y puntaje, **sin generar respuesta con LLM**. Permite que cada agente o sistema externo utilice su propio modelo de lenguaje para la síntesis.

Content-Type: `application/json`

Campo JSON	Tipo	Requerido	Descripción
`question`	string	**Sí**	Consulta o texto de búsqueda temática.
`top_k`	integer	No (def: 5)	Cantidad de fragmentos a recuperar (1 a 50).
`filters`	object	No	Filtros combinables: `sigla_aseguradora`, `ramo`, `numero_poliza`, `tipo_documento`, `vigencia_fecha`, `id_cliente`.

Ejemplo de Respuesta (200 OK):


```
{
  "chunks": [
    {
      "chunk_id": "a1b2c3d4-e5f6-7a8b-9c0d-1e2f3a4b5c6d",
      "content": "CLÁUSULA 3ra: DEDUCIBLE POR ACCIDENTE. En caso de colisión, el asegurado asumirá un dedu
      "score": 0.892,
      "policy_id": "POL-2024-9988",
      "page_number": 3,
      "metadata": {
        "aseguradora": "BISA",
        "ramo": "AUTOMOTOR",
        "tipo_documento": "POLIZA",
        "file_name": "caratula_bisa.pdf"
      }
    }
  ],
  "total_found": 1,
  "query": "¿Cuál es el deducible por colisión?"
}
```


POST `/api/v1/query`

Propósito: Responde preguntas formuladas en lenguaje natural sobre las pólizas digitalizadas, sintetizando una respuesta fundamentada con citas textuales a partir de fragmentos semánticos recuperados en pgvector.

6.4 Módulo de Sistema y Monitoreo (System & Health)

`GET` **`/api/v1/health`**

Propósito: Verificación básica de latido del servicio (*liveness check*). Retorna `{"status": "ok"}`.

`GET` **`/api/v1/health/system`**

Propósito: Reporte técnico completo: versión de DocEngine, motor de extracción (Docling), conectividad a PostgreSQL y modelos cargados.

7. Límites Técnicos por Archivo y Rendimiento

Para garantizar la estabilidad del servidor y evitar el agotamiento de memoria por archivos anómalos o de volumen desmedido, DocEngine aplica controles deterministas al inicio de cada petición:

Parámetro	Límite Máximo	Respuesta de Error	Comportamiento
Tamaño de Archivo	**200 MB** por archivo	`413 Content Too Large`	Rechazo inmediato antes de lectura en memoria o procesamiento.
Cantidad de Páginas	**500 páginas** por archivo	`422 Unprocessable Content`	Validación previa mediante inspección de metadatos de página.
Formato de Archivo	Solo `application/pdf`	`400 Bad Request`	Rechazo inmediato si la firma binaria de PDF no es válida.

Manejo de Documentos Extensos (ej. 2,300 Páginas)

Documentos que superen las 500 páginas deben segmentarse antes de la ingesta en fascículos lógicos (por ejemplo, carátula, condiciones particulares y anexos por separado), o procesarse mediante el flujo asíncrono configurando `max_pages_per_file` en `PerformanceConfig` para evitar timeouts en conexiones HTTP síncronas.

8. Procesamiento Asíncrono, Idempotencia y Condicionados Generales

Condicionados Generales Compartidos

En el mercado asegurador boliviano, un mismo condicionado general aplica frecuentemente a múltiples pólizas de un mismo ramo. DocEngine permite registrar el condicionado general una única vez con `tipo_documento="CONDICIONADO_GENERAL"`. Los agentes y consultas RAG pueden recuperar fragmentos del condicionado general utilizando el filtro `ramo` sin necesidad de duplicar el documento ni los vectores en cada póliza.

Ciclo de Vida de los Trabajos (Jobs)

Estado	Significado
`PENDING`	Archivo recibido y validado; en cola de ejecución en segundo plano.
`PROCESSING`	Extracción Docling, atomización de coberturas y vectorización BGE-M3 en curso.
`COMPLETED`	Documento procesado, estructurado e indexado exitosamente en PostgreSQL.
`FAILED`	Fallo controlado durante el pipeline; incluye traza legible en `error_message`.

Resumen de Integración para Desarrolladores

Flujo recomendado para agentes de IA y sistemas ERP:

1. Para búsqueda de fragmentos con LLM propio: invocar `POST /api/v1/query/search` pasando los filtros requeridos.
2. Para obtener coberturas y deducibles estructurados: invocar `GET /api/v1/policies/{policy_id}/structured`.
3. Para cargar documentos extensos: enviar con `POST /api/v1/extract/file?async_mode=true` y monitorear con `GET /api/v1/extract/jobs/{job_id}`.
4. Para reemplazar un documento suelto erróneo: eliminarlo con `DELETE /api/v1/policies/{policy_id}` y subir la versión corregida.