DOCENGINE REST API • ESPECIFICACIÓN TÉCNICA v1.0

DocEngine — Especificación Técnica de Endpoints y APIs

Manual integral de integración y arquitectura para analistas y desarrolladores. Ingesta documental, motor de sobres, persistencia vectorial y consultas semánticas RAG.

Plataforma:	DocEngine (FastAPI + IBM Docling + PostgreSQL pgvector)
Versión de la API:	v1.0.0 (Prefijo global: `/api/v1`)
Formatos de Datos:	JSON (UTF-8) / multipart/form-data
Fecha de Emisión:	Octubre 2026
Estado del Documento:	Especificación Técnica Oficial y Operativa

Índice del Contenido

1. Visión General: Propósito, formatos de intercambio y arquitectura de sobres.

2. Entornos y URLs Base: Direcciones por ciclo de vida (Desarrollo, Staging, Producción).

3. Autenticación y Autorización: Mecanismos de seguridad y cabeceras.

4. Convención Global de Errores y Respuestas: Estructura estándar JSON y códigos HTTP.

5. Paginación, Filtros y Orden: Reglas de consulta masiva y navegación.

6. Catálogo Detallado de Endpoints:
• *6.1 Módulo Extraction:* Ingesta y extracción de PDFs (archivo, URL, carpeta y catálogo de aseguradoras).
• *6.2 Módulo Policies & Envelopes:* Búsqueda, consulta y **eliminación limpia de sobres**.
• *6.3 Módulo RAG Query:* Consultas en lenguaje natural con citas textuales y diagnóstico.
• *6.4 Módulo System & Health:* Monitoreo de latido, métricas y buffer de logs.

7. Límites de Tasa (Rate Limiting) y Rendimiento: Capacidad de procesamiento y memoria.

8. Procesamiento Asíncrono e Idempotencia: Hashing SHA-256 y ciclo de vida de jobs.

1. Visión General

DocEngine es una plataforma de servicios de alto rendimiento diseñada para la digitalización, extracción estructurada, clasificación y consulta conversacional (RAG) de pólizas de seguro en Bolivia.

El sistema procesa documentos PDF complejos (nativos o escaneados con OCR), normaliza la estructura visual a Markdown estructurado y JSON, fragmenta el contenido en jerarquías *Parent-Child*, genera representaciones vectoriales densas de 1024 dimensiones utilizando el modelo local **BAAI/bge-m3**, y almacena la información tanto relacional como vectorialmente en **PostgreSQL con la extensión pgvector**.

Principios Clave de la API

- **Versionado Estricto:** Todos los endpoints de negocio están bajo la ruta base `/api/v1/`, garantizando evolución controlada y compatibilidad hacia atrás.
- **Formato Estándar:** Todas las peticiones y respuestas estructuradas utilizan **JSON** codificado en **UTF-8** (salvo la carga de archivos binarios vía `multipart/form-data`).
- **Idempotencia Nativa:** Toda ingesta documental verifica el hash criptográfico SHA-256 del archivo; si el documento ya fue procesado, no se reprocesa innecesariamente, evitando costos de cómputo y duplicación de vectores.
- **Arquitectura de Sobres (Policy Envelopes):** Los documentos no existen aislados; se agrupan lógicamente en "sobres" que representan la póliza completa (agrupando carátula, condicionados generales, condicionados particulares, liquidaciones y anexos).

2. Entornos y URLs Base

La API se despliega de forma desacoplada y puede consumirse a través de los siguientes endpoints base según el ciclo de vida del software:

Entorno	URL Base de Endpoints	Documentación Swagger UI	Propósito
Desarrollo Local	`http://localhost:8000/api/v1`	`http://localhost:8000/docs`	Pruebas locales, ejecución directa con Uvicorn.
Staging / Pruebas	`http://192.168.1.50:8000/api/v1`	`http://192.168.1.50:8000/docs`	Validación de integración y QA con clientes internos.
Producción	`https://docengine.altura.bo/api/v1`	`https://docengine.altura.bo/docs`	Servidor productivo de alta concurrencia.

> **Documentación Interactiva OpenAPI**
> DocEngine expone la especificación OpenAPI estándar en `/openapi.json` y provee interfaces interactivas para pruebas en `/docs` (Swagger UI) y `/redoc` (ReDoc).

3. Autenticación y Autorización

En la fase actual de despliegue para redes internas protegidas (VPC corporativa), los endpoints operan sin restricción de tokens públicos. Para despliegues expuestos a internet o consumo por aplicaciones de terceros, la convención estándar adoptada por la arquitectura es:

- **Encabezado HTTP:** `Authorization: Bearer <TOKEN_JWT>` o `X-API-Key: <SECRET_KEY>`.
- **Manejo de Errores de Acceso:**
  - `401 Unauthorized`: Ausencia de token o token caducado/inválido.
  - `403 Forbidden`: Credencial válida pero sin privilegios suficientes para la operación (ej. permisos de solo lectura intentando ejecutar `DELETE`).

4. Convención Global de Errores y Respuestas

DocEngine se adhiere a las mejores prácticas de diseño RESTful y convenciones estándar de FastAPI/Starlette.

Estructura Estándar de Error JSON

```
{
  "detail": "Descripción precisa y legible del motivo del error o validación"
}
```

Códigos de Estado HTTP Admitidos

Código HTTP	Significado	Contexto en DocEngine
200 OK	Éxito	La petición se procesó exitosamente y se retorna la información solicitada.
400 Bad Request	Petición inválida	Parámetros incorrectos, archivo con formato no admitido (solo se admite PDF) o payload malformado.
404 Not Found	No encontrado	El sobre (`envelope_id`), documento (`policy_id`) o recurso solicitado no existe en la base de datos.
422 Unprocessable Entity	Error de validación	Error de validación de tipos o restricciones Pydantic en los datos enviados.
500 Internal Server Error	Error interno	Excepción no controlada en el motor de extracción Docling o en PostgreSQL.
503 Service Unavailable	Servicio no disponible	El servicio de consultas RAG o la base de datos se encuentran en proceso de inicialización o fuera de línea.

5. Paginación, Filtros y Orden

Para evitar sobrecargar la memoria y el ancho de banda al listar colecciones de datos, los endpoints de consulta masiva implementan parámetros de paginación por desplazamiento:

Parámetro	Tipo	Por Defecto	Descripción
`limit`	integer	20 / 50	Cantidad máxima de registros a retornar por página (máximo permitido: 100).
`offset`	integer	0	Cantidad de registros a omitir desde el inicio del conjunto de resultados.
`company_sigla`	string	null	Filtro opcional por sigla oficial de la aseguradora (ej. `CRI` , `ALI` , `LBC`).

Ordenamiento: Los resultados se devuelven por defecto ordenados descendentemente por fecha de actualización/creación (`updated_at DESC, created_at DESC`).

6. Catálogo Detallado de Endpoints

6.1 Módulo de Ingesta y Extracción Documental (Extraction)

POST `/api/v1/extract`

Propósito: Carga un archivo PDF binario para su extracción documental, generación de Markdown, atomización de coberturas, generación de embeddings (BGE-M3) y persistencia en PostgreSQL.

Content-Type: `multipart/form-data`

Campo Form	Tipo	Requerido	Descripción
`file`	Binary	**Sí**	Archivo PDF de la póliza de seguro.
`company_sigla`	string	No	Sigla de la aseguradora (ej. `CRI`, `ALI`, `LBC`) para aplicar reglas especializadas.
`numero_poliza`	string	No	Número de póliza para vincular el documento a un sobre lógico existente o crear uno nuevo.
`ramo`	string	No	Ramo de seguro (ej. `AUTOMOTOR`, `INCENDIO`, `SALUD`).
`tipo_documento`	string	No	Clasificación documental (`POLIZA_PRINCIPAL`, `CONDICIONADO_GENERAL`, `CONDICIONADO_PARTICULAR`, `LIQUIDACION_PAGOS`, `ANEXO`).

Ejemplo de Respuesta (200 OK):


```
{
  "document_id": "4b684531-10df-4f40-84cf-8d9633e6c0c2",
  "status": "success",
  "markdown_preview": "# PÓLIZA DE SEGURO AUTOMOTOR\n\n## CONDICIONES PARTICULARES...",
  "metadata": {
    "filename": "poliza_automotor.pdf",
    "sha256": "c5d1b7a956d43e882a1738be78...",
    "page_count": 12,
    "extraction_time_seconds": 3.84,
    "company_sigla": "CRI",
    "envelope_id": "b3e0c091-6fa7-4f68-9bf9-a9a7a9354060",
    "tipo_documento": "CONDICIONADO_PARTICULAR"
  },
  "rag_report": {
    "policy_id": "4b684531-10df-4f40-84cf-8d9633e6c0c2",
    "chunks_created": 24,
    "skipped_duplicate": false,
    "envelope_id": "b3e0c091-6fa7-4f68-9bf9-a9a7a9354060",
    "tipo_documento": "CONDICIONADO_PARTICULAR"
  }
}
```

POST /api/v1/extract/url

Propósito: Descarga y procesa un documento PDF accesible a través de una URL pública.

Content-Type: `application/json`

```
// Body de Petición:
{
  "url": "https://storage.ejemplo.com/polizas/2026/poliza_9988.pdf",
  "company_sigla": "ALI"
}
```

POST /api/v1/extract/folder

Propósito: Procesa de forma recursiva por lotes todos los archivos PDF presentes en una carpeta del servidor local.

Content-Type: `application/json`

```
// Body de Petición:
{
  "folder_path": "C:/datos/polizas_ingesta/lote_enero",
  "company_sigla": "LBC",
  "recursive": true
}
```

GET /api/v1/extract/companies

Propósito: Retorna el catálogo oficial de siglas y nombres completos de las 16 compañías aseguradoras bolivianas soportadas por el motor.

Ejemplo de Respuesta (200 OK):

```
{
  "ALI": "ALIANZA COMPAÑIA DE SEGUROS Y REASEGUROS S.A.",
  "BIS": "BISA SEGUROS Y REASEGUROS S.A.",
  "CRI": "CREDINFORM INTERNATIONAL S.A. DE SEGUROS",
  "FOR": "FORTALEZA SEGUROS Y REASEGUROS S.A.",
  "LBC": "LA BOLIVIANA CIACRUZ DE SEGUROS Y REASEGUROS S.A.",
  "MSC": "NACIONAL SEGUROS PATRIMONIALES Y FIANZAS S.A."
}
```

6.2 Módulo de Pólizas y Gestión de Sobres (Policies & Envelopes)

GET `/api/v1/policies/envelopes`

Propósito: Lista los sobres de pólizas indexados, paginados y con el resumen de documentos vinculados.

Parámetro Query	Tipo	Por Defecto	Descripción
`limit`	integer	50	Máximo de sobres a devolver (1 - 100).
`offset`	integer	0	Desplazamiento para paginación.
`company_sigla`	string	null	Filtro opcional por sigla de aseguradora (ej. `CRI`).

GET `/api/v1/policies/envelopes/by-number/{numero_poliza}`

Propósito: Busca y devuelve los sobres y documentos que coincidan con el número de póliza especificado.

Parámetros: `numero_poliza` (Path, string), `company_sigla` (Query, opcional).

GET `/api/v1/policies/envelopes/{envelope_id}`

Propósito: Retorna el detalle completo de un sobre y todos sus documentos asociados a partir de su UUID único.

Ejemplo de Respuesta (200 OK):


```
{
  "id": "b3e0c091-6fa7-4f68-9bf9-a9a7a9354060",
  "numero_poliza": "POL-AUTO-998877",
  "company_sigla": "CRI",
  "ramo": "AUTOMOTOR",
  "created_at": "2026-10-01T14:20:00Z",
  "updated_at": "2026-10-01T14:22:15Z",
  "documents_count": 2,
  "documents": [
    {
      "policy_id": "4b684531-10df-4f40-84cf-8d9633e6c0c2",
      "file_name": "caratula_y_condiciones.pdf",
      "file_hash": "c5d1b7a956d43e882a1738be78...",
      "company_sigla": "CRI",
      "tipo_documento": "CONDICIONADO_PARTICULAR",
      "total_pages": 8,
      "file_size_bytes": 1045230,
      "created_at": "2026-10-01T14:20:10Z"
    },
    {
      "policy_id": "9d182741-22aa-4c55-b8dd-1a2b3c4d5e6f",
      "file_name": "plan_pagos.pdf",
      "file_hash": "a1b2c3d4e5f6...",
      "company_sigla": "CRI",
      "tipo_documento": "LIQUIDACION_PAGOS",
      "total_pages": 2,
      "file_size_bytes": 312450,
      "created_at": "2026-10-01T14:22:15Z"
    }
  ]
}
```

`DELETE` **`/api/v1/policies/envelopes/{envelope_id}`**

Propósito: Elimina de forma atómica y completa una póliza entera (sobre) y todos los documentos que contiene en la base de datos y opcionalmente en el disco local.

> **Comportamiento en Cascada y Limpieza Transaccional**
> Al invocar este endpoint, la base de datos elimina en cascada todas las tablas hijas asociadas a cada documento: `policy_chunks` (vectores), `policy_raw_md` (markdown), `policy_structured_data` (JSON de coberturas) y `policy_processing_stats` (telemetría). Al eliminarse los registros en `policies`, los hashes criptográficos quedan liberados, permitiendo volver a subir los documentos corregidos inmediatamente sin conflicto de idempotencia.

Parámetro	Ubicación	Tipo	Por Defecto	Descripción
`envelope_id`	Path	string (UUID)	**Requerido**	Identificador único del sobre a eliminar.
`delete_files`	Query	boolean	`true`	Si es `true`, busca y elimina también del disco los subdirectorios en `outputs/{SIGLA}/{filename_stem}`.

Ejemplo de Respuesta (200 OK):


```
{
  "envelope_id": "b3e0c091-6fa7-4f68-9bf9-a9a7a9354060",
  "numero_poliza": "POL-AUTO-998877",
  "company_sigla": "CRI",
  "ramo": "AUTOMOTOR",
  "deleted_documents_count": 2,
  "deleted_documents": [
    {
      "policy_id": "4b684531-10df-4f40-84cf-8d9633e6c0c2",
      "file_name": "caratula_y_condiciones.pdf",
      "file_hash": "c5d1b7a956d43e882a1738be78...",
      "company_sigla": "CRI"
    },
    {
      "policy_id": "9d182741-22aa-4c55-b8dd-1a2b3c4d5e6f",
      "file_name": "plan_pagos.pdf",
      "file_hash": "a1b2c3d4e5f6...",
      "company_sigla": "CRI"
    }
  ],
  "deleted_disk_dirs": [
    "outputs\CRI\caratula_y_condiciones",
    "outputs\CRI\plan_pagos"
  ],
  "message": "Sobre de póliza y todos sus documentos asociados fueron eliminados exitosamente."
}
```

`GET` **`/api/v1/policies/recent`**

Propósito: Retorna las pólizas más recientes con sus 6 campos canónicos normalizados (número de póliza, asegurado, ramo, documento, vigencia, prima total). Parámetro: `limit` (Query, defecto 20).

`GET` **`/api/v1/policies/search`**

Propósito: Búsqueda rápida por número de póliza, UUID o palabra clave. Parámetro: `q` (Query, string requerido).

`GET` **`/api/v1/policies/{policy_id}`**

Propósito: Obtiene la información básica de un documento específico de póliza a través de su UUID.

6.3 Módulo de Consultas Semánticas RAG (RAG Query)

POST `/api/v1/query`

Propósito: Responde preguntas formuladas en lenguaje natural sobre las pólizas digitalizadas, sintetizando una respuesta fundamentada con citas textuales a partir de fragmentos semánticos recuperados en pgvector.

Content-Type: `application/json`

Campo JSON	Tipo	Por Defecto	Descripción
`question`	string	**Requerido**	Pregunta en lenguaje natural formulada por el usuario.
`top_k`	integer	5	Cantidad de fragmentos contextuales a recuperar (1 - 20).
`similarity_threshold`	float	0.40	Umbral mínimo de similitud coseno para descartar fragmentos irrelevantes.
`filters`	object	null	Filtros de metadatos opcionales (ej. `{"company_sigla": "CRI"}`).

Ejemplo de Respuesta (200 OK):

```
{
  "answer": "La cobertura de Responsabilidad Civil Extracontractual cubre hasta un límite máximo de USD 20
  "question": "¿Cuál es el límite de responsabilidad civil y su deducible?",
  "chunks_retrieved": 3,
  "sources": [
    {
      "chunk_id": "f8a92b3c-...",
      "policy_id": "4b684531-...",
      "file_name": "condicionado_particular.pdf",
      "company_sigla": "CRI",
      "page_number": 4,
      "similarity_score": 0.884,
      "content": "CLÁUSULA 4. RESPONSABILIDAD CIVIL: Límite USD 20,000.00..."
    }
  ],
  "latency_seconds": 1.42
}
```

GET `/api/v1/query/health`

Propósito: Verifica que el modelo de embeddings BGE-M3 y el motor vectorial se encuentren cargados en memoria y listos para inferencia.

6.4 Módulo de Sistema y Monitoreo (System & Health)

`GET` **`/api/v1/health`**

Propósito: Verificación básica de latido del servicio (*liveness check*). Retorna `{"status": "ok"}`.

`GET` **`/api/v1/health/system`**

Propósito: Reporte técnico completo: versión de DocEngine, motor de extracción (Docling/PDFExtract), modelos OCR y conectividad a PostgreSQL.

`GET` **`/api/v1/health/metrics`**

Propósito: Estadísticas acumuladas: documentos procesados, páginas totales, tablas detectadas, tiempo promedio y tasa de éxito.

`GET` **`/api/v1/health/logs`**

Propósito: Consulta el búfer circular en memoria de los últimos eventos del servidor (filtrable por nivel: `level=INFO|WARNING|ERROR`, `limit=100`).

7. Límites de Tasa (Rate Limiting) y Rendimiento

Debido a que DocEngine ejecuta modelos locales de inteligencia artificial (modelos de visión OCR y modelo BGE-M3 de 1024 dimensiones), el rendimiento y la concurrencia deben gestionarse cuidadosamente:

- **Extracción e Ingesta:** Operación intensiva en CPU/GPU. Se recomienda mantener una tasa máxima de **10 a 15 documentos concurrentes** por instancia para evitar saturación de memoria RAM.
- **Consultas RAG:** Operación liviana; el modelo BGE-M3 procesa la pregunta en menos de 50ms y pgvector responde en menos de 15ms. Capacidad recomendada: **100 solicitudes por minuto por nodo**.
- **Memoria RAM Requerida:** Mínimo 8 GB (16 GB recomendado para soporte simultáneo de OCR multihilo y BGE-M3).

8. Procesamiento Asíncrono e Idempotencia

Garantía de Idempotencia Criptográfica

Cada archivo recibido se somete al cálculo inmediato de su firma SHA-256 (columna `file_hash` con restricción `UNIQUE` en la tabla `policies`). Si un archivo con el mismo hash ya existe en el sistema:

1. Se omite la costosa fase de extracción Docling y vectorización.

2. El trabajo se marca como `status: SKIPPED` en la tabla `processing_jobs`.
3. Se retorna inmediatamente el identificador existente y se asocia al sobre indicado.

Ciclo de Vida de los Trabajos (Jobs)

Estado	Significado
`PENDING`	Archivo en cola de recepción.
`PROCESSING`	Extracción Docling, chunking o vectorización en curso.
`COMPLETED`	Documento procesado e indexado exitosamente en PostgreSQL.
`SKIPPED`	Documento omitido por detección de duplicado idéntico (SHA-256).
`FAILED`	Fallo en el pipeline; incluye mensaje de error en la columna `error_message`.

Resumen de Integración para Desarrolladores

Flujo recomendado para sistemas externos (ERP / Portales Web):

1. Cargar documentos con `POST /api/v1/extract` pasando el `numero_poliza` para auto-agruparlos en un sobre.
2. Consultar el estado del sobre y sus partes mediante `GET /api/v1/policies/envelopes/by-number/{numero_poliza}`.
3. Si ocurre un error de carga o se requiere reiniciar la póliza, ejecutar `DELETE /api/v1/policies/envelopes/{envelope_id}?delete_files=true`.
4. Consultar coberturas mediante `POST /api/v1/query` en lenguaje natural.