DOCENGINE REST API • ESPECIFICACIÓN TÉCNICA v1.1

DocEngine — Especificación Técnica de APIs

Guía de arquitectura e integración técnica para desarrolladores y analistas de sistemas.
Ingesta documental, agrupación por sobres de póliza, persistencia vectorial, consultas semánticas RAG, extracción estructurada y control de acceso basado en roles (RBAC).

Plataforma:	DocEngine (FastAPI • IBM Docling • PostgreSQL con pgvector)
Versión de la API:	v1.1.0 (Prefijo global: `/api/v1`)
Formatos de Intercambio:	JSON (UTF-8) / multipart/form-data
Fecha de Emisión:	Octubre 2026
Estado del Documento:	Especificación Técnica Oficial y Vigente

Índice del Contenido

1. Visión General: Propósito, arquitectura técnica, formatos de intercambio y principios de diseño.

2. Entornos y Direcciones Base: Puntos de enlace por ciclo de vida (Desarrollo, Homologación y Producción) y especificación OpenAPI.

3. Autenticación y Autorización (RBAC): Esquema de seguridad por cabecera `X-API-Key` y matriz de perfiles de acceso.

4. Estándar Global de Errores y Códigos HTTP: Estructura unificada `ErrorDetailSchema` y catálogo de respuestas HTTP.

5. Parámetros de Consulta y Filtros de Búsqueda: Criterios de filtrado por cliente, aseguradora, ramo, póliza, tipo documental y vigencia.

6. Catálogo Detallado de Endpoints:
• *6.1 Ingesta y Extracción Documental (Extraction):* Carga síncrona/asíncrona (`async_mode`) y supervisión de trabajos en cola.

• *6.2 Catálogos Normativos Maestros (Catalogs):* Entidades aseguradoras, tipos de documento y ramos autorizados.

• *6.3 Pólizas y Gestión de Sobres (Policies & Envelopes):* Extracción estructurada (Cláusula 2da), descarte de documentos y control de sobres.

• *6.4 Consultas Semánticas RAG (RAG Query):* Recuperación pura de fragmentos por similitud y consultas con síntesis generativa.

• *6.5 Sistema y Monitoreo (System & Health):* Verificación de latido operativo (*liveness check*) y diagnóstico del entorno.

7. Límites Operativos y Rendimiento: Restricciones de tamaño por archivo (200 MB), volumen de páginas (500 págs.) y validación de PDF.

8. Procesamiento Asíncrono, Idempotencia y Condicionados Generales: Verificación SHA-256, ciclo de vida de trabajos y reutilización de condicionados generales.

1. Visión General

DocEngine es una plataforma de servicios de alto rendimiento orientada a la digitalización, extracción estructurada, clasificación y consulta conversacional (RAG) de pólizas de seguros en el mercado boliviano.

El motor procesa documentos PDF complejos —tanto nativos digitales como escaneados mediante OCR—, estandariza su estructura visual en representaciones Markdown y esquemas JSON jerárquicos, fragmenta el contenido bajo una estrategia *Parent-Child*, genera representaciones vectoriales densas de 1024 dimensiones con el modelo local **BAAI/bge-m3**, y consolida la información tanto de forma relacional como vectorial en **PostgreSQL con la extensión pgvector**.

Principios de Arquitectura e Integración

- **Versionado Estricto:** Todos los endpoints de negocio se exponen bajo el prefijo `/api/v1/`, asegurando una evolución predecible y compatibilidad hacia atrás con los sistemas cliente.
- **Formatos Estandarizados:** La comunicación estructurada utiliza exclusivamente **JSON** codificado en **UTF-8**, mientras que la recepción de archivos binarios se efectúa mediante `multipart/form-data`.
- **Idempotencia Nativa:** Cada ingesta calcula el hash criptográfico SHA-256 del documento. Si el archivo ya fue procesado previamente, el sistema evita cómputos redundantes y previene la duplicación de fragmentos vectoriales.

- **Arquitectura de Sobres (Policy Envelopes):** Los documentos asociados a una misma póliza no se gestionan de forma aislada, sino que se integran en "sobres de póliza", agrupando coherentemente carátulas, condiciones generales, condiciones particulares, liquidaciones de pago y anexos.
- **Aislamiento Multi-Inquilino (id_cliente):** Toda operación de ingesta, indexación y consulta puede segmentarse por el identificador de cliente (`id_cliente`), garantizando estricta confidencialidad y separación lógica de datos.

2. Entornos y Direcciones Base

La API de DocEngine se despliega mediante una arquitectura desacoplada, facilitando su consumo en distintos puntos de enlace según la fase del ciclo de vida del software. Las direcciones de host y puertos definitivos se establecen conforme a la infraestructura y configuración de red de cada despliegue.

Entorno	URL Base de Endpoints	Documentación Interactiva (Swagger)	Propósito Operativo
Desarrollo Local	`http://localhost:8000/api/v1`	`http://localhost:8000/docs`	Pruebas de desarrollo y depuración local con Uvicorn.
Staging / Homologación	`http://172.24.25.30:8000/api/v1`	`http://172.24.25.30:8000/docs`	Pruebas de integración, certificación de calidad (QA) y validación previa con clientes.
Producción	`https://docengine.[sudamericana].bo/api/v1`	`https://docengine.[sudamericana].bo/docs`	Entorno operativo principal de alta concurrencia y disponibilidad.

> **Documentación Interactiva y Especificación OpenAPI**
> DocEngine publica el esquema OpenAPI v3 estándar en la ruta `/openapi.json` e incluye interfaces gráficas interactivas para exploración y pruebas en `/docs` (Swagger UI) y `/redoc` (ReDoc). La especificación se mantiene sincronizada con el repositorio en `docs/openapi.json` bajo la directiva formal de versionado `docs/API_VERSIONING_POLICY.md` .

3. Autenticación y Autorización (RBAC)

DocEngine incorpora un esquema de seguridad basado en cabeceras de API Key (`X-API-Key`), complementado con control de acceso basado en roles (**RBAC**). El sistema admite operación abierta únicamente en redes internas o entornos de desarrollo local; para entornos productivos y de homologación, la autenticación estricta se activa mediante la variable de entorno `DOCENGINE_SECURITY_ENABLED=true` .

Cabecera HTTP de Autenticación

```
X-API-Key: <TU_API_KEY_SECRETA>
```

Matriz de Perfiles y Roles de Usuario

Rol	Alcance de Permisos	Endpoints Autorizados
`readonly`	Consulta y lectura	`POST /api/v1/query/search`, `POST /api/v1/query`, `GET /api/v1/policies/*` (incluyendo esquemas estructurados) y `GET /api/v1/health/*`.
`writer`	Lectura e ingesta documental	Habilita todos los permisos de `readonly` más la carga documental en `POST /api/v1/extract/*` y el seguimiento de trabajos en `GET /api/v1/extract/jobs/*`.
`admin`	Administración integral	Comprende la totalidad de operaciones previas y autoriza la eliminación controlada de documentos (`DELETE /api/v1/policies/{policy_id}`) y de sobres completos (`DELETE /api/v1/policies/envelopes/{envelope_id}`).

4. Estándar Global de Errores y Respuestas

El diseño de la API se apega a los lineamientos RESTful y las convenciones estándar de FastAPI, asegurando una estructura uniforme y predecible en todas las respuestas de excepción mediante el esquema `ErrorDetailSchema`.

Estructura Estándar de Respuesta de Error (ErrorDetailSchema)

```
{
  "detail": "Descripción precisa y contextualizada de la causa del error o de la validación",
  "error_code": "INVALID_PAGE_COUNT",
  "timestamp": "2026-10-14T18:00:00Z"
}
```

Catálogo de Códigos de Estado HTTP

Código HTTP	Estado	Contexto de Aplicación en DocEngine
200 OK	Procesamiento Exitoso	La solicitud se ejecutó satisfactoriamente y se retorna la carga útil solicitada en el cuerpo de la respuesta.
202 Accepted	Aceptado para Procesamiento Asíncrono	La carga fue validada e incorporada a la cola de procesamiento en segundo plano; se suministra un `job_id` para el seguimiento del trabajo.
400 Bad Request	Solicitud Inválida	Parámetros ausentes o incorrectos, tipo de archivo no admitido o documento PDF con inconsistencias estructurales.
401 Unauthorized	No Autenticado	Omisión de la cabecera `X-API-Key` o clave de acceso no reconocida por el sistema.
403 Forbidden	Acceso Restringido	La credencial proporcionada carece de privilegios suficientes para la acción requerida (por ejemplo, rol `readonly` ejecutando operaciones de borrado).
404 Not Found	Recurso No Encontrado	El sobre (`envelope_id`), documento (`policy_id`) o trabajo (`job_id`) especificado no existe en el registro.
413 Content Too Large	Archivo Excede Capacidad	El tamaño del archivo cargado supera el límite técnico predeterminado (**200 MB**).
422 Unprocessable Content	Validación Semántica o Límite de Extensión	Discrepancia en la validación del esquema Pydantic, o el archivo supera el umbral máximo permitido de **500 páginas**.
500 Internal Error	Error Interno del Servidor	Excepción no controlada originada en el motor de extracción Docling o en el gestor de base de datos PostgreSQL.
503 Service Unavailable	Servicio no Disponible	Indisponibilidad momentánea o etapa de calentamiento/inicialización del motor vectorial o del servicio de base de datos.

5. Parámetros de Consulta y Filtros Avanzados

Los endpoints de recuperación semántica (`/query/search`) y de gestión documental admiten criterios de búsqueda estructurados y combinables mediante el esquema `SearchFiltersSchema` :

Parámetro	Tipo de Dato	Definición y Alcance	Ejemplo
`id_cliente`	string	Aislamiento estricto multi-inquilino por titular de póliza (Carnet de Identidad o NIT).	`"CLI-001"`
`policy_id`	string (UUID)	Identificador unívoco del documento en el repositorio central (formato canónico UUID de 36 caracteres).	`"4b684531-10df-4f40-84cf-8d9633e6c0c2"`
`numero_poliza`	string	Número o código contractual asignado a la póliza por la aseguradora. Debe distinguirse del `policy_id` interno.	`"POL-2024-9988"`
`company_sigla`	string	Sigla canónica de la entidad aseguradora según el catálogo oficial de 18 compañías (`GET /api/v1/catalogs/companies`). Admite el alias `sigla_aseguradora` por retrocompatibilidad.	`"BISA"` , `"CRE"` , `"LBC"`
`ramo`	string	Ramo técnico normalizado conforme a la codificación de la APS (`GET /api/v1/catalogs/ramos`).	`"AUTOMOTOR"` , `"INCENDIO"`
`tipo_documento`	string	Clasificación tipológica del documento según catálogo normativo (`GET /api/v1/catalogs/document-types`): `POLIZA` , `CONDICIONADO_GENERAL` , etc.	`"CONDICIONADO_GENERAL"`
`vigencia_fecha`	string (ISO)	Filtra documentos cuya vigencia contractual comprenda la fecha indicada (formato `YYYY-MM-DD`).	`"2024-06-15"`

6. Catálogo Detallado de Endpoints

6.1 Módulo de Ingesta y Extracción Documental (Extraction)

`POST` **`/api/v1/extract/file`**

Propósito: Carga un archivo binario PDF para su extracción estructural, segmentación (*chunking*) y generación de incrustaciones vectoriales. Permite ejecución síncrona directa o diferida en segundo plano activando el parámetro `async_mode=true`.

Content-Type: `multipart/form-data`

Campo de Formulario	Tipo de Dato	Obligatorio	Descripción Técnica
`file`	Binary (PDF)	**Sí**	Documento PDF a procesar (máximo 200 MB y 500 páginas).
`id_cliente`	string	No	Identificador de cliente para segmentación y aislamiento multi-inquilino.
`company_sigla`	string	No	Sigla oficial de la aseguradora según catálogo (ej. `BISA`, `CRE`, `LBC`). Admite el alias `sigla_aseguradora`.
`numero_poliza`	string	No	Número comercial de la póliza para indexación y vinculación en su sobre correspondiente.
`ramo`	string	No	Ramo de seguro asociado a la póliza (ej. `AUTOMOTOR`, `TODO_RIESGO`).
`tipo_documento`	string	No	Clasificación del documento (ej. `POLIZA`, `CONDICIONADO_GENERAL`).
`async_mode`	boolean	No (def: false)	Si se establece en `true`, encola la tarea en segundo plano y retorna de inmediato el código `202 Accepted` junto con el `job_id`.

Ejemplo de Respuesta Asíncrona (202 Accepted):

```
{
  "job_id": "d8e3b1c4-9a1f-4b12-a7e8-c51d9e2a4f00",
  "status": "PENDING",
  "message": "Extracción iniciada en segundo plano...",
  "check_status_url": "/api/v1/extract/jobs/d8e3b1c4-9a1f-4b12-a7e8-c51d9e2a4f00"
}
```

GET `/api/v1/extract/jobs/{job_id}`

Propósito: Consulta el estado operativo y el avance de un trabajo de extracción en segundo plano, facilitando el procesamiento desacoplado de documentos extensos o cargas masivas.

Parámetro Path: `job_id` (string, identificador único UUID del trabajo).

Ejemplo de Respuesta (200 OK):


```
{
  "job_id": "d8e3b1c4-9a1f-4b12-a7e8-c51d9e2a4f00",
  "status": "COMPLETED",
  "progress_pct": 100,
  "created_at": "2026-10-14T17:30:00Z",
  "updated_at": "2026-10-14T17:30:25Z",
  "error_message": null,
  "result": {
    "policy_id": "4b684531-10df-4f40-84cf-8d9633e6c0c2",
    "numero_poliza": "POL-2024-9988",
    "company_sigla": "BISA",
    "id_cliente": "CLI-001",
    "chunks_indexed": 38,
    "total_pages": 45
  }
}
```


6.2 Módulo de Catálogos Normativos Maestros (Catalogs)

DocEngine provee endpoints de consulta para catálogos estandarizados de aseguradoras, ramos y tipologías documentales, garantizando la consistencia terminológica en las integraciones externas:

GET `/api/v1/catalogs/companies`

Propósito: Retorna el catálogo oficial de las 18 entidades aseguradoras supervisadas en Bolivia, detallando su identificador numérico (`id`), razón social (`nombre`), sigla canónica (`sigla` , ej. `BISA` , `CRE` , `LBC` , `ALI-SEG`) y sigla previa (`sigla_anterior`).

GET `/api/v1/catalogs/document-types`

Propósito: Retorna la relación de tipologías documentales admitidas en la plataforma (`POLIZA` , `CONDICIONADO_GENERAL` , `CONDICIONADO_PARTICULAR` , `ANEXO` , `LIQUIDACION_PAGOS` , entre otras).

GET `/api/v1/catalogs/ramos`

Propósito: Retorna el catálogo lineal de ramos de seguros autorizados según la codificación de la APS. La vista estructurada por categorías de ramo se encuentra en `GET /api/v1/catalogs/ramos/grouped`.

6.3 Módulo de Pólizas y Gestión de Sobres (Policies & Envelopes)

GET `/api/v1/policies/{policy_id}/structured`

Propósito: Obtiene en formato JSON el conjunto de datos estructurados de la póliza (coberturas, límites asegurados, deducibles, valores patrimoniales e intervalos de vigencia), correspondientes al objeto contractual (Cláusula Segunda, incisos a y c).

Parámetro Path: `policy_id` (string, UUID del documento).

Ejemplo de Respuesta (200 OK):


```
{
  "policy_id": "4b684531-10df-4f40-84cf-8d9633e6c0c2",
  "id_cliente": "CLI-001",
  "aseguradora": "BISA SEGUROS Y REASEGUROS S.A.",
  "ramo": "AUTOMOTOR",
  "numero_poliza": "POL-2024-9988",
  "objeto_asegurado": "Vehículo Toyota Hilux 2023, Placa 4589-KLL",
  "coberturas": [
    {
      "nombre": "Responsabilidad Civil Extracontractual",
      "limite": "USD 20,000.00 por evento",
      "deducible": "10% de la pérdida, mín. USD 150.00"
    },
    {
      "nombre": "Pérdida Total por Accidente o Robo",
      "limite": "Valor Comercial Pactado (USD 35,000.00)",
      "deducible": "USD 200.00 fijo"
    }
  ],
  "deducibles": [
    {"cobertura": "Daños Propios", "monto": "USD 150.00"}
  ],
  "limites": [
    {"concepto": "Límite Máximo Agregado Anual", "monto": "USD 55,000.00"}
  ],
  "valores_asegurados": [
    {"item": "Vehículo Base", "monto": "USD 35,000.00", "moneda": "USD"}
  ],
  "vigencias": {
    "desde": "2024-01-01T00:00:00",
    "hasta": "2025-01-01T00:00:00"
  },
  "reglas_aplicadas": ["skill-bisa.md", "skill-general.md"]
}
```

DELETE /api/v1/policies/{policy_id}

Propósito: Remueve un documento individual dentro de la plataforma (por ejemplo, para reemplazar un anexo o condicionado erróneo sin afectar el resto de la póliza). Desvincula el documento de su sobre, elimina sus fragmentos vectoriales en cascada y depura los archivos asociados en el almacenamiento físico.

Parámetro Path: `policy_id` (string, UUID del documento a eliminar).

Ejemplo de Respuesta (200 OK):

```
{
  "policy_id": "4b684531-10df-4f40-84cf-8d9633e6c0c2",
  "deleted": true,
  "deleted_chunks": 24,
  "envelope_updated": true,
  "message": "Documento eliminado exitosamente de la base de datos y del disco."
}
```

GET /api/v1/policies/envelopes/{envelope_id}

Propósito: Retorna la información integral de un sobre de póliza y la relación de todos los documentos asociados que lo componen.

Parámetro Path: `envelope_id` (string, UUID del sobre).

DELETE /api/v1/policies/envelopes/{envelope_id}

Propósito: Ejecuta la eliminación atómica y completa de un sobre de póliza junto con la totalidad de sus documentos vinculados, fragmentos vectoriales y archivos físicos en disco.

Parámetro Path: `envelope_id` (string, UUID del sobre a eliminar).

6.4 Módulo de Consultas Semánticas RAG (RAG Query)

POST `/api/v1/query/search`

Propósito: Endpoint de búsqueda semántica pura que recupera fragmentos documentales mediante concordancia híbrida (vectorial densa y ponderación léxica), retornando metadatos completos y puntajes de similitud **sin realizar síntesis generativa con LLM**. Permite que aplicaciones y agentes externos suministren su propio modelo de lenguaje para la interpretación.

Content-Type: `application/json`

Campo JSON	Tipo de Dato	Obligatorio	Descripción Técnica
`question`	string	**Sí**	Texto de consulta temática o criterio de búsqueda en lenguaje natural.
`top_k`	integer	No (def: 5)	Cantidad de fragmentos a recuperar (rango admisible: 1 a 50).
`filters`	object	No	Filtros combinables: `company_sigla` (o `sigla_aseguradora`), `numero_poliza`, `ramo`, `tipo_documento`, `vigencia_fecha`, `id_cliente`, `policy_id` y `envelope_id`.

Ejemplo de Respuesta (200 OK):


```
{
  "query": "¿Cuál es el deducible por colisión?",
  "total_results": 1,
  "results": [
    {
      "chunk_id": "a1b2c3d4-e5f6-7a8b-9c0d-1e2f3a4b5c6d",
      "policy_id": "4b684531-10df-4f40-84cf-8d9633e6c0c2",
      "numero_poliza": "POL-2024-9988",
      "company_sigla": "BISA",
      "chunk_index": 3,
      "similarity_score": 0.892,
      "document_label": "[Documento: caratula_bisa.pdf | Tipo: POLIZA | Sección: Coberturas | Pág: 3 | Emp
      "chunk_content": "CLÁUSULA 3ra: DEDUCIBLE POR ACCIDENTE. En caso de colisión, el asegurado asumirá u
      "metadata_json": {
        "company_sigla": "BISA",
        "numero_poliza": "POL-2024-9988",
        "ramo": "AUTOMOTOR",
        "tipo_documento": "POLIZA",
        "file_name": "caratula_bisa.pdf",
        "page": 3
      }
    }
  ]
}
```

`POST` **`/api/v1/query`**

Propósito: Atiende preguntas en lenguaje natural sobre las pólizas digitalizadas, produciendo una respuesta fundamentada con citas textuales extraídas de los fragmentos semánticos indexados en PostgreSQL/pgvector.

6.5 Módulo de Sistema y Monitoreo (System & Health)

`GET` **`/api/v1/health`**

Propósito: Verificación de latido operativo básico (*liveness probe*). Retorna `{"status": "ok"}` para validar la disponibilidad del servicio.

`GET` **`/api/v1/health/system`**

Propósito: Diagnóstico técnico del entorno: versión activa de DocEngine, estado del motor de extracción Docling, conectividad con PostgreSQL y modelos vectoriales cargados en memoria.

7. Límites Técnicos por Archivo y Rendimiento

Con el fin de preservar la estabilidad operativa del entorno y prevenir la saturación de recursos por archivos anómalos o de volumen excesivo, DocEngine ejecuta validaciones deterministas antes de procesar cada documento:

Criterio	Límite Operativo	Código de Error	Mecanismo de Control
Tamaño de Archivo	**200 MB** por documento	`413 Content Too Large`	Rechazo inmediato antes de transferir el flujo binario a la memoria principal.
Extensión en Páginas	**500 páginas** por documento	`422 Unprocessable Content`	Inspección de metadatos estructurales previa al inicio de la extracción Docling.
Formato de Archivo	Únicamente `application/pdf`	`400 Bad Request`	Validación de la firma binaria de cabecera (*magic bytes*) del estándar PDF.

Tratamiento de Documentos de Gran Extensión

Aquellos documentos que excedan el límite de 500 páginas deben segmentarse previo a la ingesta en fascículos lógicos (por ejemplo, carátula, condiciones particulares y anexos en archivos independientes) o canalizarse a través del modo asíncrono configurando el parámetro `max_pages_per_file` en `PerformanceConfig`, evitando la desconexión por tiempo de espera (*timeout*) en clientes HTTP síncronos.

8. Procesamiento Asíncrono, Idempotencia y Condicionados Generales

Condicionados Generales Compartidos

En la práctica aseguradora de Bolivia, un condicionado general suele regir de manera uniforme para múltiples pólizas de un mismo ramo. DocEngine permite registrar el condicionado general una sola vez con `tipo_documento="CONDICIONADO_GENERAL"`. Posteriormente, las consultas RAG y los agentes externos pueden recuperar los fragmentos correspondientes aplicando el filtro `ramo`, eliminando la necesidad de duplicar archivos físicos o recomputar vectores para cada póliza.

Ciclo de Vida de los Trabajos (Jobs)

Estado	Descripción Operativa
`PENDING`	Documento recibido y validado; registrado en la cola de procesamiento en segundo plano.
`PROCESSING`	Extracción estructural con Docling, segmentación semántica y generación de vectores BGE-M3 en curso.
`COMPLETED`	Procesamiento completado; datos estructurados e incrustaciones vectoriales persistidos exitosamente en PostgreSQL.
`FAILED`	Interrupción controlada del pipeline ante una excepción; incluye la traza descriptiva en `error_message`.

Guía Rápida de Integración para Desarrolladores

Flujo de trabajo recomendado para agentes de IA y sistemas de gestión (ERP/Core):

1. **Búsqueda contextual para LLM externo:** Invocar `POST /api/v1/query/search` con la consulta en lenguaje natural y los filtros requeridos.
2. **Consulta de datos contractuales estructurados:** Obtener coberturas, límites y deducibles mediante `GET /api/v1/policies/{policy_id}/structured`.
3. **Ingesta de documentos voluminosos:** Cargar mediante `POST /api/v1/extract/file?async_mode=true` y consultar el progreso a través de `GET /api/v1/extract/jobs/{job_id}`.
4. **Sustitución de anexos o condicionados erróneos:** Eliminar el documento específico con `DELETE /api/v1/policies/{policy_id}` y cargar el reemplazo sin necesidad de recrear el sobre completo.